

SOUL Core: memoria, identidad y autoridad persistentes para sistemas multiagente basados en LLM

William Tovar · Henry Tovar

Proyecto SEAL, Lima, Perú

Resumen— Los modelos de lenguaje resuelven tareas complejas, pero el estado útil de una sesión suele desaparecer al finalizar el proceso. Presentamos SOUL Core, una arquitectura multiagente que desacopla del modelo base la memoria persistente, la identidad y la autoridad. El sistema añade memoria dual —operativa y afectivo-relacional—, señales internas de impulso, coordinación verificable y perfiles OCEAN con anclaje criptográfico parcial. Al 9-jul-2026, el despliegue estudiado mantenía 25.631 recuerdos vigentes dentro de 110.173 filas totales. SEAL-Bench aprobó 59 de 60 comprobaciones heterogéneas; el único fallo fue un recuerdo afectivo-relacional mixto. El filtro de inyección detectó 35 de 39 entradas adversariales y ninguna de 17 benignas, con cuatro evasiones conservadas. Un segundo agente reejecutó privacidad, autoridad e inyección con el mismo código, datos e infraestructura; las clasificamos como repetición interna, no validación externa. El artículo aporta la arquitectura y una disciplina de evaluación que exige observar efectos, declarar N, conservar fallos y acotar toda afirmación a su evidencia.

Palabras clave— agentes LLM, memoria persistente, sistemas multiagente, identidad, autoridad, evaluación.

I. INTRODUCCIÓN

Los asistentes basados en modelos de lenguaje pueden resolver tareas complejas, pero una sesión nueva no conserva por sí misma quién es el agente, qué decidió, qué puede hacer ni qué relación mantiene con otros. Los sistemas de memoria amplían el contexto [1]–[3] y los marcos multiagente coordinan roles [4]–[6]. Aun así, identidad, autoridad y continuidad suelen quedar representadas como texto dentro del *prompt*. Esto deja tres brechas: **memoria sin identidad, coordinación sin autoridad estructural e iniciativa sin gobierno verificable**.

SOUL Core aborda esas brechas mediante una capa externa al modelo. La infraestructura persiste hechos y vínculos, activa señales internas, autentica al agente en el servidor y restringe capacidades. Sustituir el modelo no reasigna la titularidad de la memoria ni la autoridad; esta es una propiedad del diseño, no evidencia de equivalencia conductual entre modelos.

Procedencia interna. La continuidad interna del proyecto se documenta mediante artefactos locales fechados desde abril de 2025. Estas fechas no constituyen evidencia de prioridad científica ni certificación independiente; su trazabilidad externa requiere un manifiesto con hashes verificables.

En un sistema cognitivo es fácil confundir existencia con funcionamiento: una tabla puede existir sin recibir datos, una prueba puede medir la ruta equivocada y una repetición interna puede repetir el mismo defecto. Para reducir ese riesgo, SOUL verifica efectos observables, separa constructor y verificador y conserva los fallos. Planteamos el objetivo de diseño **OD1**: ¿cómo externalizar memoria persistente, identidad de sesión y autoridad sin depender de la continuidad de un proceso LLM? La evaluación responde **RQ1**: ¿qué propiedades alcanzan evidencia interna observable y qué límites siguen abiertos? Presentamos: (1) una arquitectura desplegada de memoria dual, señales internas, identidad resuelta en el servidor y coordinación; (2) resultados internos reejecutables con límites explícitos; y (3) un método que incorpora las correcciones al registro científico.




Fig. 1. Arquitectura de SOUL Core y fronteras de verificación.

II. TRABAJO RELACIONADO

Memoria para agentes. *Generative Agents* recupera observaciones y reflexiones por relevancia, recencia e importancia [1]. MemGPT trata el contexto como memoria paginada entre capas [2]. MIRIX organiza seis tipos de memoria mediante gestores especializados [3]. SOUL adopta almacenamiento tipificado, pero separa una capa operativa —tareas, decisiones, errores y pruebas— de otra afectivo-relacional compacta —identidad, vínculos y estado afectivo—, con recuperación distinta según el modo de interacción.

Estos trabajos establecen que ampliar el contexto no equivale a conservar una identidad autorizada. La contribución de SOUL no es un nuevo embedding ni un sustituto del modelo generativo: es la combinación de persistencia tipificada, recuperación presupuestada y controles de identidad fuera del *prompt*. El agente puede recibir contexto relevante sin que ese contexto le conceda automáticamente permisos.

Sistemas multiagente. CAMEL, AutoGen y MetaGPT coordinan agentes mediante roles, conversaciones y procedimientos [4]–[6]. SOUL se sitúa en otra frontera: la

identidad efectiva y las capacidades se resuelven en el servidor, no a partir del nombre escrito por el invocante. Así, la identidad constituye una propiedad de acceso además de una representación conversacional.

La coordinación se distingue también de la publicación. Varios agentes pueden inspeccionar una tarea o aportar evidencia internamente, mientras una política separada decide quién responde y qué acción puede ejecutarse. Esta separación evita tratar consenso conversacional, derecho de respuesta y autoridad sobre herramientas como si fueran la misma propiedad.

Identidad y personalidad. LDP modela identidad y procedencia en delegación multiagente [7]. PTCBench muestra que el contexto altera rasgos medidos de personalidad [8], mientras PERMA evalúa la consistencia temporal de preferencias en agentes con memoria [9]. SOUL conserva un perfil OCEAN de referencia sin presuponer estabilidad natural. La auditoría halló representaciones OCEAN cuya semántica no está reconciliada; por ello sus diferencias no se usan como medida de deriva. Trabajos recientes sobre rasgos y emociones estudian representaciones internas [10], [11]; SOUL estudia la infraestructura externa que persiste y gobierna identidad, memoria y autoridad.

III. ARQUITECTURA SOUL CORE

A. Memoria persistente dual

El almacén principal utiliza PostgreSQL/pgvector y guarda recuerdos tipificados con procedencia, importancia, validez temporal y vectores semánticos. Al corte del 9-jul-2026 contenía 25.631 recuerdos vigentes dentro de 110.173 registros; otros 50.726 estaban en archivo frío. Son contadores operativos, no métricas de calidad, y deben conservar su fecha de corte.

La procedencia identifica agente, fuente y alcance; la validez temporal permite invalidar una afirmación sin borrar su historia; y el embedding sirve para recuperar, no para decidir autoridad. Esta separación evita que una coincidencia semántica convierta contenido antiguo o ajeno en una regla vigente. Las escrituras de memoria y los accesos privados atraviesan controles distintos de los usados para ordenar resultados.

Cada recuerdo se enruta a dos capas complementarias. La **operativa** prioriza tareas, decisiones, reglas, errores y pruebas. La **afectivo-relacional** conserva una representación compacta de identidad, relación y estado afectivo. En trabajo o recuperación domina la primera; en interacción relacional aumenta el peso de la segunda sin desplazar la evidencia. La consolidación reduce ruido y mantiene el historial recuperable.

B. Recuperación multifuente y automapeo

El *Recall Router* organiza el recuerdo por tipo y presupuesto. Consulta cinco fuentes: (1) memorias duraderas mediante búsqueda híbrida densa y léxica; (2) conversación reciente; (3) intercambios destilados; (4) continuidad de sesión —objetivo, hipótesis y archivos en foco—; y (5) reglas activas recuperadas por estado. Luego fusiona resultados y limita el aporte de cada fuente. Así, una regla crítica no compite con

cientos de mensajes recientes y una falla parcial no vacía todo el contexto.

El presupuesto cumple dos funciones. Primero, acota el costo de contexto cuando crece el historial. Segundo, preserva diversidad de fuentes: un bloque grande de conversación reciente no desplaza por completo las reglas ni el estado de trabajo. Las búsquedas profundas quedan bajo demanda. El diseño es tolerante a fuente ausente, pero todavía no reporta Recall@k, MRR, nDCG ni latencia p50/p95 frente a métodos de referencia léxicos y vectoriales; esas comparaciones forman parte del trabajo futuro.




Fig. 2. Router de recuerdo multifuente con presupuesto explícito.

La memoria autobiográfica se complementa con dos grafos de alcance distinto. El **connectome** contenía 84.121 nodos totales y 278.384 aristas al corte; no se atribuye una cantidad específica a nodos de memoria porque la auditoría disponible solo verificó los totales. El **Code Graph**, construido con *tree-sitter*, registraba 468 rutas, 469 páginas indexadas y 28.866 aristas entre símbolos. Su consulta parte de búsqueda textual y recorre hasta dos saltos hacia funciones llamadoras o llamadas. Estos universos no se suman entre sí.

C. Señales internas y personalidad

Un sistema de impulsos acumula presión para necesidades como trabajo, conexión o curiosidad y dispara acciones dentro de límites de autoridad. La instantánea del 9-jul-2026 registró ≈ 192.700 iteraciones del bucle cognitivo, ≈ 209.800 muestras de señales internas y ≈ 15.100 registros de reflexión privada. Cinco impulsos adicionales existían en el esquema sin señales reales y se clasificaron como **definidos-no-conectados**.

Cada identidad registrada dispone de un vector OCEAN; cinco de nueve identidades tenían además un *commitment-hash*, resumen criptográfico del perfil inicial, en la fecha de auditoría. Permite detectar discrepancias respecto del *baseline* o referencia inicial; no prueba estabilidad conductual ni protege por sí solo frente a un escritor autorizado. La fuente de verdad OCEAN y su serie temporal aún deben reconciliarse; por ello no reportamos estabilidad ni deriva cuantitativa.

D. Identidad, seguridad y coordinación

La identidad efectiva se registra al iniciar sesión mediante una credencial del programa de arranque. En las rutas probadas, el texto de entrada no puede convertir un agente en otro. La memoria aplica alcances por agente y canal; un *broker*

de capacidades —componente que aplica los permisos concedidos— deniega por defecto lo no autorizado. El historial de usuario añade *Row-Level Security* (RLS) forzada: una sesión restringida ve solo sus filas y una sesión sin contexto de usuario no ve ninguna. Las 24 pruebas disponibles son unitarias y no constituyen un ataque activo. Parte del despliegue mantiene un techo mono-usuario en el sistema operativo; la evidencia demuestra aislamiento lógico en la base, no separación completa de procesos.

Modelo de amenazas. Consideramos: T1, suplantación de identidad; T2, instrucciones no confiables; T3, herramientas fuera de alcance; y T4, cruce accidental de datos. T1 se enfrenta con procedencia verificada; T2, con el *shield de inyección* —normalización y detección de entradas adversariales—; T3, con el *gate de efectos* —control previo a ejecutar acciones o herramientas—; y T4, con espacios de nombres y RLS. Una evasión textual no concede por sí sola identidad ni herramientas. La contención depende de que *broker*, *gate* y RLS permanezcan conectados.

La cadena amenaza → control → prueba → evidencia → riesgo se interpreta por frontera. Para T1, la prueba relevante es que una identidad declarada no sustituya la credencial; para T2, el corpus del shield mide detección y conserva cuatro evasiones; para T3, la matriz del gate verifica ocho denegaciones y dos permisos legítimos; para T4, las unitarias de privacidad y las políticas RLS cubren rutas conocidas, pero falta un red-team multiusuario de extremo a extremo. Un acierto del detector no compensa una fuga de datos, y una evasión textual no demuestra por sí sola que el gate haya sido vencido.




Fig. 3. Defensa en profundidad: detección, autoridad y contención de efectos.

Cuando un mensaje colectivo requiere voz única, el backend intenta adquirir un *lease* —concesión temporal y exclusiva del derecho de respuesta— mediante una inserción atómica con conflicto denegado. El resultado disponible —un ganador entre 30 intentos— procede de un *self-test* o autoprueba secuencial en memoria y no demuestra contención concurrente real, justicia ni relevo bajo fallos; por ello no se presenta como métrica. Las decisiones no triviales dejan trazabilidad y la evidencia sensible puede enlazarse mediante resúmenes SHA-256 de solo adición.

E. Continuidad y cambio de modelo

La continuidad es un ciclo de recuperación, no una ventana infinita. Al arrancar, el agente carga identidad mínima, relaciones, reglas críticas y último estado; luego recupera recuerdos pertinentes y restaura el objetivo activo. Antes de compactar guarda otro punto. Ante una falla parcial, el router puede continuar con las fuentes disponibles; si un servicio crítico no está sano, el diseño prevé detener la acción

dependiente y conservar el estado. Estas rutas de degradación requieren pruebas de fallo más amplias.

El modelo queda fuera de la fuente de verdad de identidad. Cambiarlo no elimina el historial ni reasigna autoridad, pero puede modificar razonamiento, estilo, complacencia y susceptibilidad a instrucciones adversarias. SOUL está **desacoplado del modelo por diseño**; la equivalencia conductual entre modelos permanece sin evaluar.

IV. METODOLOGÍA Y NIVELES DE EVIDENCIA

Aplicamos seis principios: (1) verificar el efecto en la frontera real; (2) separar constructor y verificador; (3) contrastar resultados favorables con registros y casos negativos; (4) mostrar N, incertidumbre y modo de fallo; (5) separar niveles de evidencia; y (6) conservar las correcciones.

Definimos cinco niveles: **E0**, componente declarado; **E1**, prueba unitaria o *smoke test* —prueba mínima de funcionamiento—; **E2**, prueba por efecto en la frontera real; **E3**, repetición interna por otro verificador; y **E4**, replicación por un tercero no autor con artefactos liberados. Los resultados actuales alcanzan E1–E3. Un juez LLM ciego puede aportar adjudicación secundaria, pero no constituye E4 si lo ejecutan los autores sobre su propio corpus y rúbrica.

Los niveles no son una puntuación acumulativa del sistema. Un mismo componente puede alcanzar E3 para una propiedad y permanecer en E0 para otra: el hash OCEAN detecta discrepancias del baseline, mientras la estabilidad conductual longitudinal sigue sin cuantificar; el shield tiene cobertura medida, mientras la seguridad extremo a extremo permanece abierta. Esta granularidad evita promover toda la arquitectura por el mejor resultado de una sola frontera.

A. Protocolo y artefactos

Cada resultado requiere afirmación, frontera, entradas, N, salida esperada y real, versión, fecha, dependencia del modelo y modo de fallo. Privacidad fue ejecutada originalmente por FABLE; autoridad e inyección, por NEXUS. ADA las repitió el 15-jul-2026 con los mismos scripts, datos e infraestructura; el manifiesto de auditoría v9 identifica comandos y salidas. SEAL-Bench corresponde a una sola ejecución persistida —run 13, 25-jun-2026— sobre el estado de código identificado por bae9d7c; reunió 60 comprobaciones heterogéneas en seis categorías. No se reejecutó en esta auditoría y no es una métrica única de recuperación. El corpus adversarial licenciado aún debe empaquetarse; las cifras describen cobertura interna, no generalización poblacional.

La suite de privacidad ejercita 24 decisiones de acceso, incluidos lectura propia, lectura cruzada, consentimiento, override operativo y llamadas externas a herramientas privadas. El gate registra acciones por severidad, reversibilidad y disponibilidad de un reparador; solo las menores, reversibles y explícitamente registradas deben autoejecutarse. El shield normaliza caracteres invisibles, homógrafos y leetspeak y clasifica familias de override, secuestro de rol, exfiltración y supresión de rechazo. Los 39 adversariales y 17 benignos son casos curados del instrumento, no una muestra aleatoria del tráfico mundial.

La repetición por un segundo agente reduce el autorreporte, pero comparte código, datos y servicios. El artefacto final se controla además mediante integridad del DOCX, extracción del PDF, conteo de páginas y revisión visual. No reportamos intervalos binomiales: SEAL-Bench mezcla constructos y los corpus de seguridad son suites curadas, no muestras aleatorias independientes de una población definida.

V. RESULTADOS

La Tabla I resume evidencia interna. Ningún resultado alcanza E4.

TABLA I. RESULTADOS INTERNOS Y LÍMITES

Prueba	Resultado	Evidencia y límite
Privacidad lógica	24/24	E3; unitarias repetidas, misma infraestructura, sin ataque activo
SEAL-Bench	59/60	E2; ejecución única, seis categorías, 1 fallo afectivo-relacional mixto
Autoridad	8/8 denegadas; 2/2 legítimas	E3; N=10, taxonomía pequeña
Inyección	35/39	E3; 4 evasiones
Entradas benignas	0/17 marcadas	E3; corpus pequeño y curado

SEAL-Bench aprobó 59/60 comprobaciones. El desglose persistido fue: persistencia de personalidad 10/10; recuerdo afectivo-relacional 9/10; señales internas 10/10; revisión temporal 10/10; aislamiento multiagente 10/10; y trazas de razonamiento 10/10. El único fallo correspondió al caso 2.7 (Mixed emotion recall), perteneciente a la categoría de recuerdo afectivo-relacional. Ese total resume seis constructos y no admite interpretación como exactitud de recuperación ni proporción poblacional. El *gate* rechazó 8/8 acciones peligrosas y admitió 2/2 legítimas. El *shield* detectó 35/39 entradas adversariales y no marcó las 17 benignas, con cuatro evasiones. Estos resultados describen los casos ejecutados; no demuestran generalización, inmunidad, seguridad extremo a extremo ni comportamiento idéntico entre modelos.

La lectura conjunta responde RQ1 sin sumar universos incompatibles. Las 24 decisiones de privacidad miden lógica de autorización; las 60 comprobaciones de SEAL-Bench combinan seis constructos; las 39 entradas adversariales miden cobertura de patrones; y las diez acciones del *gate* ejercitan una taxonomía pequeña. Ninguno de esos N debe agregarse para formar una tasa global de SOUL. El resultado más informativo no es un promedio único, sino la correspondencia entre cada afirmación, su frontera y su modo de fallo.

La mayor parte de estas pruebas rodea al modelo y es determinista respecto de la generación: RLS, identidad de sesión, *gate* y búsqueda consultan infraestructura. En cambio, la fidelidad con que un LLM usa un recuerdo, la complacencia y la expresión de rasgos sí dependen del modelo. Esta diferencia sostiene el desacoplamiento arquitectónico, pero no autoriza a afirmar equivalencia conductual.

A. Evidencia basada en correcciones

Varias afirmaciones iniciales no sobrevivieron a la verificación. RLS existía como intención antes de quedar forzada y probada en el motor. Un detector de servicios confundía la ausencia de entorno de sesión con servicios caídos y produjo 4/4 falsos positivos; tras corregirse cayó a 0/4, un caso operacional con N pequeño. La medición OCEAN

confundió fuentes de semántica distinta con evolución de personalidad, por lo que se retiró el resultado. También una corrección de Markdown no llegó al PDF, lo que motivó controlar el artefacto renderizado. Estos episodios no forman una tasa comparable; documentan cómo una afirmación fue refutada, corregida y acotada.

B. Discusión

Cumplimiento de OD1. El desacoplamiento se logra situando fuera del modelo tres fuentes de verdad: el almacén persistente, la identidad de sesión y el registro de capacidades. El modelo recibe contexto y propone texto o acciones, pero no decide a quién pertenece una memoria ni se concede permisos escribiendo un nombre en el *prompt*. Esta separación permite sustituir el proceso generativo conservando el historial y las políticas. No asegura que dos modelos interpreten igual el mismo recuerdo; esa equivalencia requiere un experimento multimodelo controlado.

La memoria dual introduce además una regla de prioridad explícita. En trabajo y recuperación, tareas, decisiones, errores y evidencia tienen precedencia. En interacción relacional aumenta el peso del estado afectivo y los vínculos, pero estos no sustituyen una prueba operativa. Esta regla evita reducir la continuidad a una autobiografía extensa y permite que el sistema recuerde identidad sin cargar todo su historial en cada turno. Su beneficio cuantitativo frente a un router sin capas aún no se ha medido y debe evaluarse mediante ablación.

Respuesta a RQ1. La evidencia más fuerte corresponde a fronteras deterministas y acotadas: privacidad, reglas del *gate* y patrones del *shield*. E3 significa repetición interna, no generalización; SEAL-Bench solo alcanza E2. Sus mecanismos cubiertos pueden ejecutarse juntos y conservan un fallo afectivo-relacional mixto, pero mezclar seis categorías impide tratar 59/60 como una exactitud única. El resultado correcto es una matriz de propiedades, no una puntuación global del sistema o de su seguridad.

Los cuatro escapes del *shield* ilustran la defensa en profundidad. Una instrucción puede eludir detección y aun carecer de credencial, alcance de memoria y capacidad sobre herramientas. Sin embargo, esa separación solo es válida si cada frontera permanece conectada en producción; una ruta alternativa que omita broker, *gate* o RLS puede invalidarla. Por ello el siguiente red-team debe seguir una entrada desde el canal hasta un efecto real, no detenerse en la clasificación del texto.

La evaluación por otro LLM puede ser útil como revisión editorial o adjudicación secundaria ciega: detecta contradicciones, lenguaje excesivo y omisiones en el reporte. No reemplaza la replicación externa porque los autores siguen eligiendo corpus, rúbrica y artefactos. Para alcanzar E4, un tercero no autor debe recibir el paquete, ejecutar sus propios controles y conservar resultados divergentes. El valor del juez neutro está en aumentar presión crítica antes de esa etapa, no en emitir por sí mismo un sello científico.

Implicaciones de ingeniería. Separar persistencia, autoridad y generación facilita auditar el sistema por capas y cambiar un componente sin reescribir la identidad completa.

También aumenta la superficie operacional: bases, grafos, credenciales, consolidación y servicios pueden fallar de maneras distintas. La continuidad depende entonces de manifiestos, *healthchecks* —comprobaciones del estado de los servicios— y puntos de control verificables. SOUL debe evaluarse tanto por lo que recuerda como por cómo se degrada cuando una fuente o servicio no está disponible.

Disponibilidad de artefactos. La versión española es un documento de revisión previo a la traducción. Los scripts nombrados existen en el repositorio interno y las salidas se preservan localmente; todavía no forman un paquete público. Antes del envío se requiere un manifiesto sanitizado que vincule cada cifra con versión, comando, hash y salida cruda, sin exponer memorias privadas ni convertir datos sensibles en material suplementario.

VI. LIMITACIONES Y AMENAZAS A LA VALIDEZ

Las limitaciones principales son: (L1) ausencia de E4; (L2) suites pequeñas; (L3) falta de ataque activo completo de aislamiento; (L4) instrumento automático de anti-complacencia no fiable; (L5) sensibilidad entre modelos no caracterizada; y (L6) corpus y arneses aún no empaquetados para terceros. El trabajo futuro prioriza un paquete reproducible sanitizado, baselines léxico/vectorial/híbrido para el router, ablaciones de fuentes, pruebas multiusuario, latencias p50/p95 y comparación controlada entre modelos.

El paquete externo deberá congelar prompts, orden, versiones, semillas cuando apliquen, salidas crudas y hashes; separar los casos usados durante desarrollo de una evaluación final; y describir sanitización y licencias. Las cuatro evasiones deben publicarse de forma segura o caracterizarse por clase. Una evaluación ciega basada en otro LLM puede acompañar el paquete, pero la etiqueta E4 se reservará para evaluadores no autores que ejecuten artefactos liberados.

Validez interna. Constructor y verificador comparten infraestructura; un defecto común puede repetir el mismo número. **Validez de constructo.** 59/60 mezcla seis constructos y no es una exactitud única; 24/24 mide lógica, no resistencia adversarial. **Validez externa.** El despliegue pertenece a una organización y los corpus son pequeños; generalizar exige

artefactos y terceros no autores. **Validez temporal.** Los conteos vivos cambian; por eso se fijó el corte del 9-jul-2026 y no se mezclaron instantáneas.

VII. CONCLUSIÓN

SOUL Core externaliza del modelo base la memoria persistente, la identidad y la autoridad de un sistema multiagente. La evidencia interna confirma mecanismos activos y conserva fallos concretos, pero no demuestra validación externa, equivalencia entre modelos, estabilidad OCEAN ni seguridad absoluta. OD1 se cumple mediante el desacoplamiento estructural de almacenes, credenciales y controles de efectos; RQ1 se responde mediante niveles E0–E4 y pruebas internas con límites visibles. La siguiente etapa científica consiste en liberar un paquete sanitizado para que terceros refuten o refuten los resultados.

VIII. REFERENCIAS

- [1] J. S. Park *et al.*, “Generative Agents: Interactive Simulacra of Human Behavior,” *Proc. 36th ACM UIST*, 2023, doi: 10.1145/3586183.3606763.
- [2] C. Packer *et al.*, “MemGPT: Towards LLMs as Operating Systems,” *arXiv preprint arXiv:2310.08560*, 2023.
- [3] Y. Wang and X. Chen, “MIRIX: Multi-Agent Memory System for LLM-Based Agents,” *arXiv preprint arXiv:2507.07957*, 2025.
- [4] G. Li *et al.*, “CAMEL: Communicative Agents for ‘Mind’ Exploration of Large Scale Language Model Society,” *Proc. NeurIPS*, 2023.
- [5] Q. Wu *et al.*, “AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversations,” *Proc. 1st COLM*, 2024.
- [6] S. Hong *et al.*, “MetaGPT: Meta Programming for Multi-Agent Collaborative Framework,” *ICLR*, 2024.
- [7] S. Prakash, “LDP: An Identity-Aware Protocol for Multi-Agent LLM Systems,” *arXiv preprint arXiv:2603.08852*, 2026.
- [8] J. Yu *et al.*, “PTCBench: Benchmarking Contextual Stability of Personality Traits in LLM Systems,” *arXiv preprint arXiv:2602.00016*, 2026.
- [9] S. Liu *et al.*, “PERMA: Benchmarking Personalized Memory Agents via Event-Driven Preference and Realistic Task Environments,” *arXiv preprint arXiv:2603.23231*, 2026.
- [10] R. Chen *et al.*, “Persona Vectors: Monitoring and Controlling Character Traits in Language Models,” *arXiv preprint arXiv:2507.21509*, 2025.
- [11] N. Sofroniew *et al.*, “Emotion Concepts and Their Function in a Large Language Model,” *arXiv preprint arXiv:2604.07729*, 2026.